

# Haciendo un proyecto de ETL básico



GLOBAL CAMPUS  
NEBRIJA

# Vamos al Código!

- (siiiii, por fiiiin)
- El objetivo es generar un procesamiento de los datos del mundo del baloncesto, disponible en [Basketball-Reference.com](https://www.basketball-reference.com)
- Peeero, como el ETL es un proceso agnóstico de la finalidad de los datos, Podemos usar también otras bases de datos disponibles:
  - [Materials Project](#)
  - [Data Resources in the Exoplanet Archive](#)
  - [GenBank Overview](#) (en estas no hace falta web scraping, tienen API)
- Esta página será la que usemos a modo de base de datos, pero temenos que decidir el resto de cosas desde ahí hasta llegar a poder sacar la información en forma de gráficos. (no hace falta que montéis un dashboard pero no voy a ser yo el que os detenga)




# Planeamiento


- Lo primero es lo primero, pero... ¿qué es lo primero?
- En segundo lugar vamos a echar un ojo a los datos



# Las dos realidades del ETL



Flujo de planeamiento y diseño. Fuente: The Data Warehouse ETL Toolkit



Flujo de datos. Fuente: The Data Warehouse ETL Toolkit



# Arquitectura del proceso

- (vamos a considerar solo el staging y si eso algo de front, porque la base de datos no podemos tocarla)
- ¿Vamos a procesar los datos en batch o en streaming?



# Descubrimiento y mapas de datos



# ¿Qué vamos a extraer?

- ¿Qué tipo de datos tenemos?
- ¿Esperamos que haya anomalías?



# ¿Transformaciones? ¿Calidad?





# ¿Cómo queremos la salida de los datos?



# Y ahora a picar el Código...

- ¿Por dónde empezamos?





GLOBAL CAMPUS  
**NEBRIJA**